SteelDig | SFT 与数据库汇报

优化版独立讲稿 · 对应 41 页 PPT · 2026-10-25

PPT 内无演讲者注释。新增背景与研究结果附公开来源；现有统计沿用原页历史口径。

第 01 页 | SFT 及数据库架构与应用进展

本次汇报分为两部分：第一部分介绍材料领域 SFT 数据建设，从微调背景、真实图谱与问答实例讲到质量审查；第二部分介绍数据库，从平台参考、四层关联讲到查询和治理。模型训练收益尚需独立实验，规模统计仍沿用各页标明的历史快照。

核对依据：用户整合后的封面与两部分结构

第 02 页 | 框架定位

本次汇报介绍的是材料领域 SFT 数据构建框架。SFT 就是监督微调，我们把已有论文抽取结果加工成问题和参考答案，让模型学习如何解释材料中的工艺、组织和性能关系。这里介绍数据构建流程，不包含模型训练效果。后面先说明整体流程，再用一个低密度钢案例串起建图、出题和审查，最后展示现有历史统计。

核对依据：README.md；run.py；模板：课题三_1024.pptx

第 03 页 | 微调是什么，为什么还需要 RAG

微调是在预训练模型上继续训练。我们这里讨论的是监督微调，也就是用问题和参考答案教模型完成材料任务，可以更新全部参数，也可以只训练适配器。SFT 主要改变模型行为和任务能力；RAG 在回答时查外部资料，把证据放进上下文，通常不更新生成模型的参数。两者可以组合：模型学会按成分、工艺、组织和性能解释问题，具体数值和出处再从数据库检索。主要难点有三类。第一，微调并不会自动消除幻觉，错误答案还可能被固化。第二，集中学习领域数据可能损害通用能力，这就是灾难性遗忘，参数高效微调也不

保证完全避免。第三，材料数据条件复杂且稀疏，需要按论文划分数据，并在未见材料或工艺上测试。RAG 也会检索错误或误读证据，因此二者都需要事实评测。

核对依据：https://arxiv.org/abs/2005.11401；https://arxiv.org/abs/2308.08747

第 04 页 | 材料领域已有研究及效果

这里选择三个代表性工作，不把不同指标排成一个排行榜。HoneyBee 的 MatSci-Instruct 使用生成器与独立验证器，并通过反馈逐轮改进指令数据。论文表 2 中，7B 无验证版本的 Accuracy 为 85.42，Stage 3 为 91.95。这是 GPT-4 对其生成测试集的评价分数，不是人工或实验认证的正确率，而且变化同时包含验证和迭代训练的作用。LLaMat 在材料语料上持续预训练并进行指令微调。2025 年 v2 的表 E.1 中，LLaMA-3-chat FT 与 LLaMat-3-chat 的 MatNLP 平均 Micro-F1 分别是 86.2250 和 93.0270，展示了领域适配的收益。MELT 不是 QA 指令微调，而是用语义图与课程式策略进行持续预训练；其表 1 中 SciBERT 与 MELT 的总体 Micro-F1 是 0.693 和 0.741。三项研究共同提示，数据组织与训练设计很重要，但不能据此推断本项目已经提升了模型能力。我们目前汇报的是数据建设，仍需独立训练与测试。

核对依据：https://arxiv.org/abs/2310.08511v1；https://arxiv.org/abs/2412.09560v2；https://aclanthology.org/2024.findings-emnlp.627/

第 05 页 | 为什么需要这套框架

已有抽取资产告诉我们材料是什么、经历了什么工艺、观察到了什么组织和性能。SFT 数据还需要把这些信息组织成用户会问的问题，并给出完整解释。我们重点关注四个方面的联系，例如热处理怎样改变析出相，析出相又怎样影响性能。题目必须交代研究对象，答案以定性解释为主，数值只作为佐证。

核对依据：AGENTS.md；qa/spec.py；prompts/generate.v1.txt

第 06 页 | 总流程

整条管线以单篇论文为基本处理单元。先加载结构化数据、Wiki、图表描述、公式和证据引用，再构建关系图。机制解释题与关系方向短答从图的路径和关系边派生；公式题、表征推断题和跨样本对比题也会直接使用相应资产。因此，它是关系图与资产共同驱动的框架。两条路线都先形成出题规格，再由模型生成 QA，最后执行审查和数据整理。

核对依据：run.py:_process_paper；qa/spec.py:build_specs

第 07 页 | 关系图怎样建立

建图分为三步。第一步不用模型，直接把已有结构化数据映射成节点，并建立样品包含工艺、组织等结构关系。第二步把 Wiki 中的机制叙述交给模型，要求只在现有节点和受控关系词表内输出关系边。第三步将首尾相接的边尝试合成机制路径，这是较轻量的路径构建。图检查可以发现无效端点、词表外关系和缺证据情况，但当前发现问题后只记录告警，不会自动阻止后续生成。关系边证据主要由两端节点来源合并而来，不能把它等同于关系本身已经被原文逐条证明。

核对依据：graph/entities.py；graph/relations.py；graph/paths.py；graph/verify.py；graph/build.py

第 08 页 | 为什么设计五类任务

五类任务分别锚定不同的知识组织方式。机制解释面向因果链，方向短答面向促进或抑制，对比题面向同一合金不同工艺，公式题面向用途和适用条件，证据推断题面向表征现象。默认每个规格请求两个变体，实际保留数量还受到生成结果、审查和去重影响。我们不生成选择题或负样本，答案以定性解释为主。当前图片相关 QA 主要使用已有图像描述生成，图片路径会附入训练样本，但生成和审查并未直接读取图片像素。

核对依据：qa/spec.py；qa/generate.py；config/sft.config.json；prompts/generate.v1.txt

第 09 页 | 实例：资产到关系

这个例子来自一篇低密度钢腐蚀论文。对象是热轧后水淬、没有再做固溶处理的 Fe-Mn-Al-C 钢。结构化资产描述了工艺和保留的纳米 κ-碳化物，Wiki 给出了相关机制解释。

我们可以把它整理成一条便于理解的关系：残留碳化物消耗基体中的 Al，使可用于表面成膜的固溶 Al 供应受限，进而影响富 Al 膜的连续形成和保护能力。这里的四段链是为汇报整理的可读表达，不声称图文件已经把每个中间环节都作为独立节点。示意图不是显微照片，也不代表新增实验结果。

核对依据：历史 records.jsonl 中 κ-碳化物样例；source/selected_example.json；对应 relation_path

第 10 页 | 把真实子图展开看

前一页讲的是便于理解的科学机制，这一页展示实际保存的图谱。该 QA 对应 path-5，连接三类节点：κ-carbide、interface_S0 和 perf_S0_baseline，边是 r5 的 suppresses 和 r9 的 causes。三个节点都属于同一个热轧水淬样品。需要特别澄清，interface_S0 在原始资产中保存的是 γ / κ 界面、缺陷相互作用和相演化信息，并不是一个专门的氧化膜节点；关于富 Al 膜形成受限的机制保存在 r5 的文本中。r9 再描述膜保护能力不足与耐蚀性较差的关系。路径把这两条边文本拼接，提供出题焦点。这样既能看见实际图结构，也能看出当前节点粒度还不够细。原始节点 ID、属性、关系与证据引用均另存到配套 source 文件，便于复核。

核对依据：sft_mechanism_qa/out_sft/graph/10.1016_j.corsci.2025.113331.json：path-5 / r5 / r9；sft_mechanism_qa/out_sft/records.jsonl：mqa_mechanism_forward_10.1016_j.corsci.2025.113331_1

第 11 页 | 代码怎样把子图变成问答

代码先遍历机制路径，并根据路径两端节点找到所属样品。对 path-5，出题规格的 qa_type 是 mechanism_forward，anchor_ids 是 r5 和 r9，relation_path 保存两段节点关系，focus 使用路径的 mechanism 文本。接着构造事实卡，补充成分、工艺、Wiki 机制以及研究对象说明，并合并路径证据、样品证据和解释性段落引用。generate_variants 实际发送给模型的是题型、出题焦点、事实卡和要求生成的条数；不是把整张图或完整 QaSpec JSON 直接发过去。机制解释题要求围绕原因和后果提问，于是这条路径被转成为什么 κ-碳化物限制保护膜形成的问题。S0 被完整的成分与工艺描述替代，r5 等内部代号也不会进入训练问答。答案再根据事实卡解释 Al 被占用、成膜供应受限和保护性下降。页面问题为保留样例的精简展示，完整原文在配套文件中。

核对依据：sft_mechanism_qa_pipline/sft_mechanism_qa/qa/spec.py：_path_sample_and_labels / build_specs；sft_mechanism_qa_pipline/sft_mechanism_qa/qa/generate.py：generate_variants；source/qa_case.json

第 12 页 | 实例：关系到问答

生成模型拿到题型、机制焦点和事实卡，生成自然语言问答。这里展示的是一条实际保留样例的精简版本，完整对象在上一页已经交代，原始题目包含成分和工艺。答案按 AI 被占用、成膜供应受限、保护能力下降三个层次解释，避免只有一个结论。右侧分数来自原始完整 QA 的历史评审记录，不是对本页精简文本重新评分。初审四维分别是 9.5、9、9、9.5，平均 9.25；复核平均 8.75。两轮评审都通过，但模型高分本身不等于经过独立实验或人工验证。

核对依据：source/selected_example.json；qa/generate.py；gate/l2.py

第 13 页 | 审查怎样决定去留

L0 是纯规则检查，主要守住格式和身份表达等硬约束，包括证据字段非空。通过后再进行四维评分，每维满分 10 分，当前平均分至少 7 分，任何一维不能低于 6 分。最后默认还有一次交叉评审，使用另一套提示词重新审视同一个 QA。最终任何一道未通过都会拒绝；代码依据分数计算结论，不直接信任模型自报的 passed。无法解析评审结果也会保守拒绝。当前没有把拒绝意见反馈给生成器自动修改的闭环。

核对依据：run.py:_gate_record / _process_spec；gate/l0.py；gate/l2.py；gate/__init__.py；config/sft.config.json

第 14 页 | 可追溯不等于严格事实验证

每条记录可以保存论文、样品、关系路径、文本块或图表公式引用，以及审查分数和原因，便于定位问题。但这里需要区分四点。第一，L1 原文逐论断核验已有实现却没有接入当前主流程。第二，生成、初审和复核使用同一配置模型，复核只是另一次调用和不同提示词。第三，图片相关数据虽然带图片路径，当前生成和评审调用使用的是文字描述。

第四，图检查问题主要进入统计，并未变成强制阻断。因此现阶段更适合称为有溯源和质量筛选的数据构建，而不是逐句完成原文验证。

核对依据：qa/generate.py；qa/spec.py；gate/l1.py；gate/l2.py；cli.py；graph/verify.py；run.py

第 15 页 | 数据怎样交付和扩展

最终交付有三部分。训练文件只保留训练需要的指令、答案和图片字段；审计文件保留更完整的来源、关系路径、题型和评审信息；图谱和统计文件支持后续分析。管线提供两层并发，默认两篇论文同时处理，每篇内部四个规格并发。通过的 QA 会继续去重，去重后的记录按论文分组划入训练、验证或测试，避免同篇论文的内容跨集合。当前单篇历史示例只有训练集数据，不能据此声称已经形成独立评测集。

核对依据：run.py；dedup.py；split.py；export.py；config/sft.config.json

第 16 页 | 后续工作

当前代码已经实现从资产读取到训练数据导出的链路，包括五类题型、规则与模型评审、去重、按论文划分和图谱保存。下一步建议分为三件事：先对关键机制和数值增加原文回查；再把样本归属和关系证据检查变得更严格；最后扩充论文覆盖，建立独立的验证和测试数据。这些是规划，不是已经完成的功能，也没有在本次汇报中声称模型能力已经提升。

核对依据：当前实现：run.py、graph/、qa/、gate/、export.py；规划依据：本次代码核查结论

第 17 页 | 历史数据统计

最后这一页是本地找到的历史示例统计，不代表最新批量总量。这次对应一篇低密度钢论文，77 个出题规格生成 154 条候选，审查拒绝 4 条，剩余通过记录在去重时移除 76 条，最终保留 74 条。注意，审查通过率和最终净产出比例不是同一指标。题型分布为证据推断 30 条、公式机制 21 条、机制解释 16 条、关系短答 6 条、跨样本对比 1 条。图谱包含 60 个节点、90 条边和 18 条路径。因为只有一篇论文，按论文划分后全部进入训练集，验证和测试为空。工作区还有旧版其他框架的数据，本页没有合并，以免统计

口径混淆。后续可以直接修改 PPT 末页的数字和图表数据；如需重新生成，请按交付说明同步更新统计与源码。

核对依据：source/historical_data_card.json；sft_mechanism_qa/out_sft/data_card.json；records.jsonl 行数 74；rejected.jsonl 行数 4

第 18 页 | 数据库建设

下面进入数据库部分。我们把论文解析和抽取资产组织成可查询、可回查、可校订的数据底座。先说明建设结果与平台参考，再解释四层如何通过处理流程和共同标识连接，最后展示查询、证据追踪和维护能力。数据库与 SFT 管线目前各自已有能力，数据库专用的训练导出集成仍属于后续工作。

核对依据：README.md；用户整合后的章节页

第 19 页 | 建设成果：从论文到可用数据

先看已经形成的成果。68 篇论文中组织出 250 个合金、638 个样品和 1,508 条性能值，其中 1,304 条可数值化。样品不是只按成分区分，同样成分经历不同工艺，也要作为不同样品记录。支撑这些事实的还有 10,316 个原文证据块、68,944 条溯源记录和 5,099 条检索文档。这里的溯源记录覆盖样品的多类字段，不能把它理解成每条性能都对应固定数量的证据。成果的价值在于把数据与证据、查询和修订连接起来。

核对依据：README.md 数据规模；04_reports/qa_report.md

第 20 页 | 建设目标：五项核心能力

数据库的目标可以归纳成五项能力。存得住，是保留原始材料并稳定组织数据；查得到，是能够按成分、性能或研究问题查找；改得动，是人工修订可以保留下来；说得清，是能解释数值来自哪篇论文、哪段证据；用得上，是让材料研究者通过页面和接口使用。这五项能力既包含查询，也包含数据长期维护，后面的架构就是它们的落点。

核对依据：00_ARCHITECTURE_PLAIN.md §0、§4

第 21 页 | 具体借鉴哪些平台，数据长什么样

Materials Project 是已有设计文档明确参考的平台。它使用稳定 material_id 组织晶体结构与性质，支持元素筛选、详情页和 API。左侧展示来自 Materials Project 的真实计算数据快照，由 matminer 的 dielectric_constant 数据集收录，对应 Petousis 等人在 2017 年发表的公开数据。条目 mp-7029 为 SiO2，空间群编号 96，计算胞含 12 个原子，PBE 带隙为 5.51 eV，总介电常数的平均值为 4.04。这是注明来源和年代的计算数据，不是当前 API 实时结果，也不是实验测量；其完整 structure、CIF 和性质保存在配套快照。官方 API 文档则用于核对稳定 ID、字段选择与计算来源追踪方式。右侧是本库真实论文样品，Fe–12Mn–9Al–3Cr–1.4C–0.02Nb 铸态钢，屈服强度 880±19 MPa、抗拉强度 1016±12 MPa、延伸率 39±2%，对应文献 DOI 10.1002/srin.202400475。两类条目的身份不同：MP 按晶体结构组织，我们按论文与实验样品组织，相同成分不同工艺也分开。企业平台方面参考 Databricks 的 Medallion 分层理念，但其三层数据精炼流程不能与本库四层一一等同；AI 检索平台方面参考 Pinecone 的向量与元数据设计，本库实际使用的是 pgvector。这两项是本次新增的设计对照，不声称项目历史上采用过这些产品。

核对依据：https://doi.org/10.1038/sdata.2016.134；https://ndownloader.figshare.com/files/13213475；https://docs.materialsproject.org/downloading-data/using-the-api/examples；https://docs.materialsproject.org/downloading-data/using-the-api/querying-data；https://docs.databricks.com/aws/en/lakehouse/medallion；https://docs.pinecone.io/guides/search/filter-by-metadata；02_extraction/10.1002_srin.202400475/output/sample/sample_fe-12mn-9al-3cr-1.4c-0.02nb__as-cast.data.json

第 22 页 | 总体架构：四层分工协同

这张图从下往上看。资产湖保留解析与抽取产生的 JSON、图片，使用内容指纹管理；事实源把它们组织为数据库表，同时保留原始 JSON；检索层为不同查询方式建立索引；消费层向研究者和程序提供页面与接口。溯源、校订、质量治理贯穿这些层。把变化速度不同的东西分开，才能独立改页面、升级检索或重新入库。还要注意：当前湖后端是本地目录，并没有部署对象存储；资产湖之外的原始 PDF、清单，以及数据库中的校订记录，

也要纳入保存策略。 四层是逻辑分工，事实表与检索索引当前共用一个 PostgreSQL 实例，下一页用实际字段解释如何连通。

核对依据：00_ARCHITECTURE_PLAIN.md §2；README.md 分层一览；06_db/etl/steeldig_db/lake.py

第 23 页 | 四层之间靠什么连接

这页把上一页的概念架构落实到代码。首先，JSON 和图片进入本地资产湖，以 SHA-256 命名。lake.object_ref 把论文号和逻辑路径映射到 object_id，lake.object 再给出物理文件位置。第二，ETL 读取输入，在单篇论文事务中写入 core 表，论文号与样品号把成分、工艺、组织和性能关联起来；字段证据再通过 path 连接到 sample_trace 和 evidence_block。第三，searchidx.build_docs 从论文、Wiki、图表、公式等事实生成检索文档，保留 doc_id、paper_id、sample_id 和 ref_id。中文分词生成检索文本，数据库维护全文和模糊索引，向量字段通过单独的嵌入步骤填充，不是每次修改都天然自动重算。第四，API 用参数化 SQL 查询：数值条件可以直接查事实视图，不必经过向量检索；自然语言问题调用混合检索，结果携带来源标识。图表原图访问则先找到 core.figure.image_paths，再经 lake.object_ref 和 lake.object 取文件。需要区分数据库外键和应用层约定，search.document 的来源字段主要依靠 ETL 与应用保持一致，并非全部声明为外键。

核对依据：06_db/etl/steeldig_db/lake.py；06_db/etl/steeldig_db/ingest.py：load_paper；06_db/etl/steeldig_db/searchidx.py：_doc / build_docs；06_db/migrations/020_lake.sql；050_search.sql；06_db/api/steeldig_api/web.py：figure_image / sample_detail

第 24 页 | 数据流水线：每一步都有产物

从 PDF 到数据库，主要经过版面解析、结构化抽取和校验入库。解析产生文字、表格、图片及版面信息，抽取进一步整理成成分、工艺、性能等 JSON，入库阶段进行数据转换和关联。各阶段产物都会保留，便于从适当环节重跑。工程上有三条规则：单篇论文在同一事务中写入，避免半篇数据；重复入库避免重复累积；只把 output 下的定稿当作事实输入，过程日志单独留档。历史文档记录的约 30 秒针对当时的入库规模，不包括重新解析和模型抽取。

核对依据：00_ARCHITECTURE_PLAIN.md §5；ingest.py load_paper

第 25 页 | 可靠存储：资产与事实分离

资产湖与事实源承担不同职责。湖中有 6,667 个对象、约 148 MB，主要是 JSON 和图片；事实源约 332 MB，包含 36 张表和 12 个视图。内容指纹能够检测文件内容变化，也帮助去重，但它本身不是访问控制或备份机制。事实层可以根据保留的输入与清单重新入库，湖则保存证据资产。PDF 原文仍留在 01_raw 中。完整恢复还需要考虑来源清单、校订记录和必要配置，不能只备份资产湖就认为万事具备。

核对依据：00_ARCHITECTURE_PLAIN.md §2、§4；README.md；07_CRUD.md

第 26 页 | 数据模型：以样品连接材料信息

数据模型以样品为中心。论文提供来源，合金描述成分，而样品还包含具体的工艺状态。例如相同成分在铸态和时效态下，强度与延伸率可能明显不同，必须分别建样品。每个样品向下连接性能、工艺步骤、相和组织信息，再通过字段路径和证据块回到论文。这张图是为讲解简化的关系图，并不是所有表和外键的完整 ER 图。这样的组织方式支持跨样品分析，同时保留实验上下文。

核对依据：00_ARCHITECTURE_PLAIN.md §6；01_SCHEMA.md；qa_report.md

第 27 页 | 字段设计：可筛选，也保留原文

字段设计采用结构化列与 JSONB 配合。身份标识、外键和常用筛选维度，适合做成有类型的列，比如年份、性能种类、数值和单位。不同论文差异较大的描述和条件，则保存在 payload 中，避免为每一种表达都增加新列。例如原文的 685 MPa，一方面拆成可比较的数值和标准单位，另一方面保留原始表达。以后增加查询需求时，可以从保留的信息中补字段。这是查询便利和信息保真之间的平衡。

核对依据：00_ARCHITECTURE_PLAIN.md §6.4；030_core.sql

第 28 页 | 组织方式：稳定身份与性能长表

性能采用长表，每一行表示某个样品的一种性能。页面用简化示意展示同一样品的屈服强度、抗拉强度和延伸率。真实记录还会保留误差、条件和原始表达。这样增加新的性能类型主要是增加记录，而不是不停增加列。身份也要稳定：样品编号只在论文内部有意义，因此关联时必须带论文号。跨论文先使用标准词表做分类，不把相似名称自动视为同一个材料。代价是展示一个样品的完整性能时，需要再组合查询结果。

核对依据：00_ARCHITECTURE_PLAIN.md §6.1、§6.3、§6.5、§6.6

第 29 页 | 检索设计：匹配不同的研究问法

研究者有不同问法。成分区间、性能阈值等明确条件，由结构化筛选承担；关键词检索可以寻找 TWIP 或某类碳化物的相关片段；语义检索则面向自然语言研究问题，按意思相近的程度召回材料。三路文本召回是全文、模糊和向量，它们使用 RRF 合并名次信息；准确公式是各路 1 除以 60 加名次，再求和，不是简单把名次相加。语义相似度也不代表科学结论成立，最终还需要查看证据。中文查询与入库采用一致的分词处理。

核对依据：00_ARCHITECTURE_PLAIN.md §7；050_search.sql（RRF 实现）

第 30 页 | 应用示例：按成分寻找候选材料

成分检索是材料研究者很直接的入口。页面通过元素周期表选元素，再设质量分数区间。查询先给出精确匹配；如果没有合适结果，近邻候选会明确说明偏离了哪个元素、差了多少，而不会伪装成满足条件。Fe 经常在论文里写成余量，系统会根据其他元素推算，并做推断标记。项目文档记录 243 个 Fe 基合金中，4 条 Fe 含量为原值，239 条为推断值。使用这些数值时，要保留推断来源的说明。

核对依据：07_docs/screenshots/11-composition-slide.jpg；06_QUALITY.md §4

第 31 页 | 应用示例：在样品页核对上下文

进入样品页后，先确认成分和样品状态，再查看工艺、组织和性能。研究上最容易出问题的是把相似成分、不同处理状态的数据直接混用，因此这里把上下文放在同一页面。性能

值旁边提供证据入口；能够定位原文的记录可以继续核对，定位不足的则标出弱溯源。页面同时保留原始数据视角，帮助使用者判断哪些值适合比较。截图展示的是已有功能，用于汇报时稳定说明操作路径。

核对依据：07_docs/screenshots/03-sample-top.jpg；00_ARCHITECTURE_PLAIN.md §4

第 32 页 | 证据追踪：从性能值回到论文

这里展示一个实际例子：铸态样品的屈服强度为 880 正负 19 MPa。抽取记录能够关联正文 b0035 和表格 b0049。正文说明铸态到时效后的变化，而表格包含 880 正负 19 的完整报告值，所以误差项也需要核对表格，不能只看正文截句。论文 DOI 为 10.1002/srin.202400475。全库 1,508 条性能值都可以定位到论文，其中 1,133 条能够进一步定位段落或表格，375 条明确标为弱溯源。75% 是证据覆盖率，既不是数值准确率，也不是全部溯源记录的覆盖率。 这条真实样品的标识是 sample_fe-12mn-9al-3cr-1.4c-0.02nb__as-cast，论文号是 10.1002_srin.202400475。字段路径为 $.properties[0].mechanical.tensile_properties.yield_strength[0]，当前代码采用这种 JSONPath 风格路径。property_value 与 sample_trace 在论文号、样品号、run_id 和 path 上对齐，block_id 再在同一论文内定位证据。

核对依据：_reframe_notes.md §5；02_extraction/10.1002_srin.202400475/preprocess/evidence_blocks.json；样品 data.json

第 33 页 | 人工校订：重跑后仍然有效

人工修订通过独立的校订记录管理。上方原始资产重新生成事实数据，下方校订记录再自动重放到事实层，然后页面读取当前结果。每条校订记录包含目标字段、前后值、理由、操作人和时间，避免直接改表后被重跑覆盖。新增论文通过入库流程，人工增改删则受白名单限制。撤销也有具体边界：更新可以恢复旧值；如果此前执行了删除，撤销后还需要重新入库恢复事实行。当前校订立即生效，尚未具备多人审批流程，因此多人协作治理仍是下一阶段工作。

核对依据：07_CRUD.md §2、§4、§5、§6；curate.py

第 34 页 | 来源管理：区分批次与历史版本

来源批次与历史版本需要分开理解。当前 68 篇论文来自四个抽取批次，分别覆盖 13、4、4 和 47 篇，run_id 能追踪它们的来源。表结构中也预留了按 run 和 is_latest 管理版本的能力。但是核对当前入库实现后可以看到，系统会先删除该篇论文并级联清理事实，再写入新结果，因此不能承诺同一论文多次重跑的全部历史事实已经保留。人工校订日志是另一类历史，当前可以记录和审计。后续应补充按批次保存历史的写入策略，再开展可靠的多模型对比。

核对依据：03_manifests/paper_runs.json；030_core.sql sample_data；ingest.py load_paper

第 35 页 | 应用出口：页面、接口与研究流程

消费层同时面向人和程序。10 个页面支持浏览、检索和分析，22 个接口提供结构化访问。截图展示自然语言检索的入口，用户可以从问题找到相关证据，再返回样品或文献核对。对于 AI 应用，这样的底座可以让回答引用检索到的事实和出处。但要区分已经完成的能力与后续产品：目前有证据检索和接口，不应直接把它说成已经交付了完整的问答 Agent；用于模型训练的专用数据导出流程也还没有完成。

核对依据：README.md；00_ARCHITECTURE_PLAIN.md §2.2、§10；05-search.jpg

第 36 页 | 质量治理：通过检查，也保留问题

质量指标要按各自口径解释。保存的报告中 error 级为零，warn 级共有 844 条，主要分为 821 条图观察项缺证据、15 条证据 ID 未解析告警和 8 条章节字段泄漏告警。证据 ID 的可解析率是 99.94%，它衡量的是标识对齐，不是性能值准确率。项目文档记录 95 项测试通过，这次 PPT 制作没有重新启动服务跑全套测试。因此页面明确写成文档记录。零工程错误说明满足既定一致性检查，但抽取内容仍然需要科学核验和持续补充。

核对依据：04_reports/qa_report.md；07_docs/06_QUALITY.md

第 37 页 | 数据使用：保留数值背后的含义

能够计算不等于可以直接比较。1,508 条性能记录中，1,304 条可数值化；172 条是定性描述，这两个类别也不是把全部数据简单二分后就能解释完。区间、误差和其他不可解析表达需要各自保留。硬度尤其要区分标尺，不能因为都是数值就放在同一张强度图里。Fe 余量推断要带标记，不能冒充原文测量值。另外，174 个样品缺少结构化性能，文档抽查指出部分属于上游漏抽。后续要改进抽取覆盖率，而不是只在数据库内填补缺失数字。

核对依据：04_reports/qa_report.md 属性量；06_QUALITY.md 已知缺陷

第 38 页 | 技术选型：控制当前系统复杂度

选 PostgreSQL 的核心原因是当前阶段可以用较少组件同时覆盖结构化查询、JSON 保真、全文和模糊检索，并通过 pgvector 支持语义检索。这样减少了不同系统之间的同步、备份和监控成本。并不是其他数据库不具备这些能力，而是项目目前规模较小，统一技术栈的收益更直接。随着检索量和并发上升，可以评估外迁检索层；决策应该看真实的容量、查询延迟、索引内存和更新压力，不能把线性估算当成已经完成的压测结论。

核对依据：00_ARCHITECTURE_PLAIN.md §8、§10；050_search.sql

第 39 页 | 平台定位：可引用的文献事实底座

SteelDig 的定位是面向文献材料事实的数据底座。重点是论文中的成分、工艺、组织和性能怎样对应到具体样品，又怎样找到原文证据和后续修订。与 Materials Project 等外部材料库之间可以形成互补，但不宜把所有外部数据库都简单说成没有溯源的结果库。未来可以关联计算数据和文献实验数据，并列展示它们的方法和来源。跨库对齐需要验证，尤其不能把计算值和实验值混成同一个事实记录。

核对依据：00_ARCHITECTURE_PLAIN.md §1、§11；05_MATERIALS_PROJECT.md

第 40 页 | 当前边界：走向持续服务还需补齐

当前阶段完成的是本地数据底座、检索和应用入口，接下来要补齐持续服务能力。首先是数据安全与恢复，包括账号权限、备份和恢复演练；其次是多人协作，包括审批和并发冲突检测；第三是完善真正保留历史事实的版本写入，再做多模型对比。应用侧还需要专用训练数据导出和跨库关联。规模扩展则通过容量和延迟评估决定，而不是先引入更多组件。原材料中的 30 秒入库和更大规模推算，都只适合作为当时环境的观察与估算，不能当作生产承诺。

核对依据：00_ARCHITECTURE_PLAIN.md §10；07_CRUD.md §6；ingest.py

第 41 页 | 下一步：从可用走向持续可信

下一步分三组推进。数据质量上补抽缺失性能、补齐证据并完善单位标记；治理能力上落实历史事实保留，再进行多模型对比，同时补齐权限、审批和恢复演练；研究应用上形成规范化训练数据导出，并逐步验证跨论文与外部数据库的关联。最终希望形成的，是一套能查、能改、能审，而且可以持续维护的材料研究数据底座。我的汇报到这里，谢谢。

核对依据：README.md 下一步方向；00_ARCHITECTURE_PLAIN.md §10；源码核对

术语速查

SFT：用问题与参考答案进行监督训练。

RAG：先检索外部资料，再把证据放进模型上下文生成答案。

持续预训练：在领域文本上继续语言建模训练，与指令 QA 微调不同。

灾难性遗忘：学习新任务后，原有任务能力下降。

QaSpec：生成问答之前确定的题型、焦点、上下文和证据引用。

JSONPath 风格字段路径：在 JSON 中定位某项字段，例如 $.properties[0]。

SHA-256：文件内容的指纹，用于对象命名和校验，不等于备份或权限控制。

RRF：把不同检索方式得到的排名合并。